

SolarFlow - Analyse descriptive

Aurélien CANDILLIER - Pierre JANNOT - Jean-Baptiste LIZE

2026-05-26

Dans l'objectif de réaliser un entraînement de modèle de Machine Learning sur des données, nous avons utilisé un pipeline Python récupérant des données météo depuis plusieurs sites différents. Avant tout entraînement, il est nécessaire de réaliser une étude des données pour vérifier s'il n'y a pas de corrections à faire.

Import des données

Importation des données et paramétrage R de la colonne timestamp.

```
data <- read_csv("output/solarflow_2026-01-01_2026-04-27_origin.csv")
data$timestamp <- as.POSIXct(data$timestamp, format = "%Y-%m-%d %H:%M:%S%z", tz = "UTC")
```

Statistiques descriptives des données produites par le pipeline Python

Affichage des minimums, maximums, moyennes, médianes et écart-types par colonne :

Production solaire (RTE)

##	min	max	mean	med	sd
##	0.000	18922.000	3126.256	259.500	4589.960


Production solaire (CSV)

##	min	max	mean	med	sd
##	0.00	75793.00	14599.32	1026.50	20085.40

Consommation totale (CSV)

##	min	max	mean	med	sd
##	0.00	282638.00	206203.97	205878.50	32849.08

Comparaison RTE/CSV et consommation d'énergie



Shortwave radiation (Meteo)

##	min	max	mean	med	sd
##	0.0000	881.0000	142.1460	0.0000	222.4204


Direct radiation (Meteo)

##	min	max	mean	med	sd
##	0.00000	752.00000	94.72828	0.00000	176.20681

Diffuse radiation (Meteo)

##	min	max	mean	med	sd
##	0.00000	405.00000	47.41774	0.00000	67.19026

Boxplot radiations




À l'exception de la consommation d'énergie, on observe pour chaque colonne une moyenne et une valeur maximale particulièrement élevées en comparaison de la médiane.

La production d'énergie solaire récupérée par le CSV est de plus beaucoup plus élevée que celle obtenue par l'API RTE, avec un rapport multiplicatif de différence de 3 à 4. Il serait donc important de comparer les valeurs agrégées des valeurs brutes du fichier csv pour vérifier qu'il n'y a pas de somme des lignes répétées.

Production solaire et irradiance

Afin de voir s'il n'y a pas des valeurs anormales, nous devons vérifier que les périodes de production d'énergie solaire les plus importantes correspondent aux périodes de plus forte irradiance. Afin de proposer une lecture plus facile, nous réalisons d'abord la moyenne journalière des valeurs et la normalisation des colonnes, puis on affiche le graphique suivant :



```
##           [,1]  
## [1,] 0.8255317
```

```
##           [,1]  
## [1,] 0.9988286
```


Le graphique obtenu montre une courbe de tendance qui représente bien la répartition des points. Les données RTE et CSV sont assez bien superposées à l'exception de quelques valeurs.

On peut maintenant afficher la production et l'irradiance en fonction du temps pour savoir si les données semblent bien corrélées.

Séparation horaire

```
## Warning: Removed 802 rows containing non-finite outside the scale range
## ('stat_boxplot()').
```

Distribution de la production par heure



Sur ce graphique on peut observer un problème majeur. Les trois types de données semblent décalés. Le pic de production des données RTE est visible à 11 h, sur le CSV à 12/13 h et sur l'irradiance à 14 h. On peut estimer que cette erreur vienne d'un décalage horaire causé par une différence dans le format horaire récupéré et dans la façon dont il est traité.

Correctif réalisé

Afin de résoudre ce problème, nous avons mis en place plusieurs correctifs sur le pipeline Python, corrigeant l'heure de certaines données, la façon dont la valeur est calculée pour le CSV qui ne présentait pas des valeurs uniques par heure ainsi que la zone géographique de récupération des données d'irradiance pour couvrir l'ensemble de la France.

On peut maintenant réaliser la même opération pour observer si les corrections ont corrigé les erreurs observées.

Statistiques descriptives des données produites par le pipeline Python

Affichage des minimums, maximums, moyennes, médianes et écart-types par colonne :

Production solaire (RTE)

##	min	max	mean	med	sd
##	0.000	18922.000	3689.305	344.000	5016.936


Production solaire (CSV)

##	min	max	mean	med	sd
##	0.000	18948.250	3657.918	273.500	5017.894

Consommation totale (CSV)

##	min	max	mean	med	sd
##	32569.500	70659.500	51839.805	51539.000	7453.308

Comparaison RTE/CSV et consommation d'énergie



Shortwave radiation (Meteo)

##	min	max	mean	med	sd
##	0.0000000	869.1666667	151.5565544	0.7083333	216.3002546


Direct radiation (Meteo)

##	min	max	mean	med	sd
##	0.00000	759.21667	99.45702	0.00000	162.39752

Diffuse radiation (Meteo)

##	min	max	mean	med	sd
##	0.0000000	271.4333333	52.0993524	0.5083333	66.3957299

Boxplot radiations




On observe ici une bien meilleure correspondance entre les données RTE et CSV qui présentent la même moyenne, la même valeur maximale et le même écart-type. Le graphique montre bien aussi que le facteur multiplicatif entre les deux jeux de données a bien été corrigé.

En ce qui concerne l'irradiance, on observe des valeurs très similaires aux précédentes, malgré l'ajout de nombreux parcs solaires français.

Production solaire et irradiance

Relation journalière normalisée (GHI vs RTE)




```
##           [,1]  
## [1,] 0.9230871
```

```
##           [,1]  
## [1,] 0.9989442
```

La corrélation observée entre les données RTE et CSV est plus importante, et les points de chaque jeu de données semblent beaucoup plus proches de la courbe de tendance.

Séparation horaire



Ici on peut observer que les données CSV et RTE présentent bien des valeurs de production d'énergie similaire aux mêmes heures. En ce qui concerne l'irradiance, malgré un recalage de 2 h, il semblerait qu'il y ait toujours un décalage avec la production d'énergie. En effet, d'après ce graphique, la production d'énergie commence à augmenter avant l'irradiance, et s'arrête avant l'irradiance.

On peut estimer qu'il y a toujours un décalage d'une heure mais qui est peut-être dû à la façon dont les données sont mesurées, cela peut par exemple correspondre à l'irradiance observée sur la dernière heure face à la production observée sur la prochaine heure.